## Predicción de la estructura secundaria de proteínas globulares

## Cristina Lendinez

## 8/4/2021

## Índice general $\overline{}$

Algoritmo K-NN	2
Step 1: Recolección de los datos	2
2.Desarrollar una función en R que implemente una codificación "one-hot" (one-hot encoding) de las secuencias.	2
3. Desarrollar un script en ${\bf R}$ que implemente un clasificador knn. El script debe realizar los siguientes apartados:	6
(a) Leer el fichero data4.csv. Cada registro contiene una secuencia de 17 aminoácidos y la clase de estructura secundaria correspondiente al aminoácido central (posición 9), donde los caracteres 'h', 'e' y '_' representan -helix, -sheet y coil, respectivamente. Después de cargar los datos, crear una tabla donde se muestre el número de secuencias de cada clase	7
(c) Utilizando la semilla aleatoria 123, separar los datos en dos partes, una parte para training (67%) y una parte para test (33%)	8
(d) Utilizar un knn $(k = 1, 3, 5, 7, 11)$ basado en el training para predecir la estructura secundaria de las secuencias del test	9
(d) Utilizar un knn $(k = 1, 3, 5, 7, 11)$ basado en el training para predecir la estructura secundaria de las secuencias del test	13
Ingreso las librerias que voy a usar	

### Algoritmo K-NN

El algoritmo K-NN utiliza la informacion de los vecinos mas cercanos para etiquetar o clasificar individuos que no tengan etiqueta o clasificación. Para ello utilizaremos un conjunto de datos para "entrenamiento" y clasificara otro conjunto de individuos que no esten clasificados. El algoritmo identificara k individuos del conjunto de datos de entrenamiento que tengan mas similitud con cada individuo a etiquetar y se asignara su clasificación. El valor k es un valor especificado de antemano.

Fortalezas	Debilidades
*Simple y efectivo	*No produce un modelo, lo que limita la capacidad de encontrar conocimientos en las relaciones entre las caracteristicas
*No hace suposiciones sobre la distribución de datos subyacentes	*Fase de clasificación lenta
*Fase de entrenamiento rápida	*Requiere una gran cantidad de memoria * Características nominales y la falta de datos requiere un procesamiento adicional

### Step 1: Recolección de los datos

# 2.Desarrollar una función en R que implemente una codificación "one-hot" (one-hot encoding) de las secuencias.

Se descargan los datos de la PEC desde la pagina de la UOC o del dataset """. Tenemos 2 archivos que estan en formato csv y tiene como separador ",". Son 2 csv, uno de ellos lo usaremos para crear la funcion **one-hot**, y si no conseguiimos crear la funcion **one-hot**, tenemos el archivo **oh\_enc** cedido por el profesor, para que podamos continuar con el análisis. Vamos a importar el primer csv, llamado *data4* Cargo el primer csv llamado data4.csv

datos <- read.csv("C:\\Users\\crist\\OneDrive\\Desktop\\machine learning\\Pec 1 Cris\\data4 .csv", head

Tengo que eliminar la columna V18, para poder crear mi variable de one-hot

```
datos2 <- datos[-18]
```

Confirmo que he eliminado la columna V18

```
str(datos2)
```

```
## 'data.frame': 10000 obs. of 17 variables:
## $ V1 : Factor w/ 20 levels "A","C","D","E",...: 16 10 10 10 17 6 6 10 16 16 ...
## $ V2 : Factor w/ 20 levels "A","C","D","E",...: 16 10 10 10 18 14 7 11 1 6 ...
## $ V3 : Factor w/ 20 levels "A","C","D","E",...: 13 14 12 12 16 20 1 18 3 3 ...
## $ V4 : Factor w/ 20 levels "A","C","D","E",...: 5 20 13 1 5 1 5 3 3 16 ...
## $ V5 : Factor w/ 20 levels "A","C","D","E",...: 16 20 9 9 4 18 12 12 18 20 ...
## $ V6 : Factor w/ 20 levels "A","C","D","E",...: 14 6 9 6 1 7 18 19 9 17 ...
## $ V7 : Factor w/ 20 levels "A","C","D","E",...: 9 11 20 4 17 6 4 15 9 10 ...
## $ V8 : Factor w/ 20 levels "A","C","D","E",...: 6 17 8 17 5 18 5 13 1 16 ...
```

```
## $ V9 : Factor w/ 20 levels "A","C","D","E",...: 3 4 13 5 1 17 3 1 5 10 ...
## $ V10: Factor w/ 20 levels "A","C","D","E",...: 4 11 6 4 5 16 3 14 1 16 ...
## $ V11: Factor w/ 20 levels "A","C","D","E",...: 15 12 17 18 10 5 16 13 8 6 ...
## $ V12: Factor w/ 20 levels "A","C","D","E",...: 20 20 9 1 8 18 4 10 8 1 ...
## $ V13: Factor w/ 20 levels "A","C","D","E",...: 9 20 11 10 9 16 3 9 3 16 ...
## $ V14: Factor w/ 20 levels "A","C","D","E",...: 20 17 18 16 16 15 9 12 14 20 ...
## $ V15: Factor w/ 20 levels "A","C","D","E",...: 18 18 5 12 13 10 1 15 3 17 ...
## $ V16: Factor w/ 20 levels "A","C","D","E",...: 3 10 13 9 3 6 18 14 9 1 ...
## $ V17: Factor w/ 20 levels "A","C","D","E",...: 13 5 6 6 16 2 10 8 16 6 ...
```

#Con la uncion str, acabo de confirmar que he eliminado la columna V18,

Seguidamente con la funcion dummy podre crear mi función **one-hot**, y tambien con la funcion one-hot, lo hago de las 2 formas para confirmar que funciona correctamente

```
data.dummy <- dummy.data.frame(datos2, sep=".")
head(data.dummy)</pre>
```

```
##
      V1.A V1.C V1.D V1.E V1.F V1.G V1.H V1.I V1.K V1.L V1.M V1.N V1.P V1.Q V1.R
## 1
          0
                0
                       0
                             0
                                    0
                                          0
                                                 0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                 0
                                                                                       0
                                                                                              0
## 2
          0
                0
                       0
                             0
                                    0
                                          0
                                                       0
                                                              0
                                                                    1
                                                                                       0
                                                                                              0
                                                                                                    0
                                                 0
                                                                           0
                                                                                 0
                                                                                                    0
## 3
          0
                0
                       0
                             0
                                    0
                                          0
                                                 0
                                                       0
                                                              0
                                                                    1
                                                                           0
                                                                                 0
                                                                                       0
                                                                                              0
                                                                                                    0
                       0
                             0
                                    0
                                          0
                                                       0
                                                              0
                                                                    1
                                                                                       0
                                                                                              0
## 4
          0
                0
                                                 0
                                                                           0
                                                                                 0
                       0
                             0
                                          0
                                                       0
                                                              0
                                                                    0
                                                                                       0
## 5
          0
                0
                                    0
                                                 0
                                                                           0
                                                                                 0
                                                                                                    0
## 6
          0
                0
                       0
                             0
                                    0
                                          1
                                                 0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                 0
                                                                                       0
                                                                                                    0
##
      V1.S
            V1.T
                   V1.V
                         V1.W
                                V1.Y V2.A V2.C V2.D
                                                         V2.E
                                                                V2.F
                                                                      V2.G
                                                                             V2.H V2.I
                                                                                          V2.K V2.L
## 1
          1
                0
                       0
                             0
                                    0
                                          0
                                                 0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                 0
                                                                                       0
                                                                                              0
## 2
          0
                       0
                             0
                                    0
                                          0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                       0
                                                                                              0
                                                                                                    1
                0
                                                 0
                                                                                 0
## 3
          0
                       0
                             0
                                    0
                                          0
                                                       0
                                                              0
                                                                    0
                                                                                       0
                                                                                              0
                                                                                                    1
## 4
          0
                0
                       0
                             0
                                    0
                                          0
                                                 0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                 0
                                                                                       0
                                                                                              0
                                                                                                    1
## 5
          0
                       0
                             0
                                    0
                                          0
                                                 0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                 0
                                                                                       0
                                                                                              0
                                                                                                    0
                       0
                             0
                                                       0
                                                              0
                                                                                       0
##
   6
          0
                0
                                    0
                                          0
                                                 0
                                                                    0
                                                                           0
                                                                                 0
                                                                                              0
                                                                                                    0
                                V2.R V2.S
##
      V2.M V2.N
                   V2.P
                         V2.Q
                                             V2.T
                                                   V2.V
                                                         V2.W
                                                                V2.Y V3.A
                                                                             V3.C
                                                                                   V3.D
                                                                                          V3.E
                                                                                                V3.F
## 1
          0
                0
                       0
                             0
                                    0
                                                 0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                       0
                                                                                              0
                                                                                                    0
                                          1
                                                                                 0
## 2
          0
                0
                       0
                             0
                                    0
                                          0
                                                 0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                 0
                                                                                       0
                                                                                              0
                                                                                                    0
                       0
                             0
                                    0
                                                       0
                                                              0
                                                                    0
                                                                                       0
                                                                                              0
                                                                                                    0
## 3
          0
                0
                                          0
                                                 0
                                                                           0
                                                                                 0
                       0
                             0
                                    0
                                                              0
                                                                    0
                                                                                       0
                                                                                              0
                                                                                                    0
## 4
          0
                0
                                          0
                                                 0
                                                       0
                                                                           0
                                                                                 0
## 5
          0
                0
                       0
                             0
                                    0
                                          0
                                                 0
                                                       1
                                                              0
                                                                    0
                                                                           0
                                                                                 0
                                                                                       0
                                                                                              0
                                                                                                    0
                                                       0
##
   6
          0
                0
                       0
                             1
                                    0
                                          0
                                                 0
                                                              0
                                                                    0
                                                                           0
                                                                                 0
                                                                                       0
                                                                                              0
                                                                                                    0
                         V3.K V3.L V3.M V3.N V3.P
                                                         V3.Q
                                                                V3.R V3.S V3.T
##
      V3.G V3.H V3.I
                                                                                   V3.V
                                                                                          V3.W
                                                                                                V3.Y
## 1
          0
                0
                       0
                             0
                                    0
                                          0
                                                 0
                                                       1
                                                              0
                                                                    0
                                                                           0
                                                                                 0
                                                                                       0
                                                                                              0
                                                                                                    0
## 2
                       0
                             0
                                    0
                                                       0
                                                                    0
                                                                                       0
                                                                                              0
                                                                                                    0
          0
                0
                                          0
                                                 0
                                                              1
                                                                           0
                                                                                 0
## 3
          0
                0
                       0
                             0
                                    0
                                          0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                 0
                                                                                       0
                                                                                              0
                                                                                                    0
                                                 1
                             0
                                                                                       0
                                                                                              0
                                                                                                    0
## 4
          0
                0
                       0
                                    0
                                          0
                                                       0
                                                              0
                                                                    0
                                                                           0
## 5
          0
                0
                       0
                             0
                                    0
                                          0
                                                       0
                                                              0
                                                                    0
                                                                                       0
                                                                                              0
                                                                                                    0
                                                 0
                                                                           1
                                                                                 0
##
   6
          0
                0
                       0
                             0
                                    0
                                          0
                                                 0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                 0
                                                                                       0
                                                                                              0
                                                                                                    1
##
      V4.A V4.C
                   V4.D
                         V4.E
                                V4.F V4.G V4.H V4.I
                                                         V4.K
                                                                V4.L V4.M
                                                                             V4.N
                                                                                   V4.P
                                                                                          V4.Q
                                                                                                V4.R
## 1
          0
                       0
                             0
                                          0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                       0
                                                                                                    0
                0
                                    1
                                                 0
                                                                                 0
                                                                                              0
                                                                                       0
                                                                                              0
                                                                                                    0
## 2
          0
                0
                       0
                             0
                                    0
                                          0
                                                 0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                 0
## 3
          0
                0
                       0
                             0
                                    0
                                          0
                                                 0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                 0
                                                                                       1
                                                                                              0
                                                                                                    0
                                                                                       0
                                                                                              0
                                                                                                    0
## 4
          1
                0
                       0
                             0
                                    0
                                          0
                                                 0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                 0
## 5
                       0
                             0
                                    1
                                          0
                                                       0
                                                              0
                                                                    0
                                                                           0
                                                                                       0
                                                                                              0
                                                                                                    0
          0
                0
                                                 0
                                                                                 0
                             0
                                    0
                                          0
                                                       0
                                                              0
                                                                    0
                                                                                       0
                                                                                              0
                                                                                                    0
## 6
                0
                       0
                                                 0
                                                                           0
                                                                                 0
          1
```

##		V4.S	V4.T	V4.V	V4.W	V4.Y	V5.A	V5.C	V5.D	V5.E	V5.F	V5.G	V5.H	V5.I	V5.K	V5.L
##	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	2	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0
##	3	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0
##	4	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0
##		0	0	0	0	0	0	0	0	1	0	0	0	0	0	0
##	6	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	1											V6.A				
##		0	0	0	0	0	1	0	0	0	0	0	0	0	0	0 0
##	3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	5	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0
##		0	0	0	0	0	0	0	1	0	0	0	0	0	0	0
##	Ū	-	V6.H	-	-	-		-			-	V6.S	-		-	
##	1	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0
##	2	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	3	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0
##	4	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	5	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	6	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0
##		V7.A	V7.C	V7.D	V7.E	V7.F	V7.G	V7.H	V7.I	V7.K	V7.L	V7.M	V7.N	V7.P	V7.Q	V7.R
##		0	0	0	0	0	0	0	0	1	0	0	0	0	0	0
##		0	0	0	0	0	0	0	0	0	0	1	0	0	0	0
##	3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	4 5	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0
##		0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	U	-	-	-	-			-	-		-	V8.G	-	-	-	
##	1	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0
##	2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	3	0	0	0	0	1	0	0	0	0	0	0	0	1	0	0
##	4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	5	0	1	0	0	0	0	0	0	0	1	0	0	0	0	0
##	6	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##					•							V9.A			V9.E	
##	_	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
##		0	0	0	0	0	0	1	0	0	0	0	0	0	1	0
##		0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
## ##		0	0	0	0	0	0	1	0	0	0	0 1	0	0	0	1 0
##		0	0	0	0	0	0	0	1	0	0	0	0	0	0	0
##	U						V9.M					V9.S		V9.V	V9.W	
##	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##		0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##		0	0	0	0	0	0	0	1	0	0	0	0	0	0	0
##		0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	5	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
##	6	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0
##		V10.A	V10			10.E V										.N V10.P
##		C		0	0	1	0		)	0	0	0	0		)	0 0
##		C		0	0	0	0		0	0	0	0	0		1	0 0
##		C		0	0	0	0		1	0	0	0	0		)	0 0
##	4	C	)	0	0	1	0	(	)	0	0	0	0	(	)	0 0

##	5	0	0	0	0	1	0	0	0	0	0	0	0	0
##	6	0	0	0	0	0	0	0	0	0	0	0	0	0
##		V10.Q	V10.R		V10.T	V10.V	V10.W	V10.Y	V11.A	V11.C	V11.D	V11.E	V11.F	V11.G
##	1	Ö	0	0	0	0	0	0	0	0	0	0	0	0
##	2	0	0	0	0	0	0	0	0	0	0	0	0	0
##	3	0	0	0	0	0	0	0	0	0	0	0	0	0
##	4	0	0	0	0	0	0	0	0	0	0	0	0	0
##	5	0	0	0	0	0	0	0	0	0	0	0	0	0
##	6	0	0	1	0	0	0	0	0	0	0	0	1	0
##		V11.H	V11.I	V11.K		V11.M	V11.N	V11.P	V11.Q	V11.R	V11.S	V11.T	V11.V	V11.W
##	1	0	0	0	0	0	0	0	0	1	0	0	0	0
##	2	0	0	0	0	0	1	0	0	0	0	0	0	0
##	3	0	0	0	0	0	0	0	0	0	0	1	0	0
##	4	0	0	0	0	0	0	0	0	0	0	0	1	0
##	5	0	0	0	1	0	0	0	0	0	0	0	0	0
## ##	6	0 V11 V	0 V12.A	0 V10 C	0 V12.D	0 V12.E	0 V10 F	0 V10 C	0 V10 H	0 V10 T	0 V10 V	0	0 V12.M	•
##	1	0	V12.A	0	0	0	0	V12.G	V12.n	0	V12.K	0	V12.M 0	V12.N 0
	2	0	0	0	0	0	0	0	0	0	0	0	0	0
##	3	0	0	0	0	0	0	0	0	0	1	0	0	0
##	4	0	1	0	0	0	0	0	0	0	0	0	0	0
##	5	0	0	0	0	0	0	0	0	1	0	0	0	0
##	6	0	0	0	0	0	0	0	0	0	0	0	0	0
##		V12.P	V12.Q	V12.R	V12.S	V12.T	V12.V	V12.W	V12.Y	V13.A	V13.C	V13.D	V13.E	V13.F
##	1	0	0	0	0	0	0	0	1	0	0	0	0	0
##	2	0	0	0	0	0	0	0	1	0	0	0	0	0
##	3	0	0	0	0	0	0	0	0	0	0	0	0	0
##	4	0	0	0	0	0	0	0	0	0	0	0	0	0
##	5	0	0	0	0	0	0	0	0	0	0	0	0	0
##	6	0	0	0	0	0	1	0	0	0	0	0	0	0
##						V13.L				-		V13.S		V13.V
##	2	0	0	0	1	0	0	0	0	0	0	0	0	0
##	3	0	0	0	0	0	1	0	0	0	0	0	0	0
##	4	0	0	0	0	1	0	0	0	0	0	0	0	0
##	5	0	0	0	1	0	0	0	0	0	0	0	0	0
##	6	0	0	0	0	0	0	0	0	0	0	1	0	0
##		V13.W	V13.Y	V14.A	V14.C	V14.D	V14.E	V14.F	V14.G	V14.H	V14.I	V14.K	V14.L	V14.M
##	1	0	0	0	0	0	0	0	0	0	0	0	0	0
##	2	0	1	0	0	0	0	0	0	0	0	0	0	0
##		0	0	0	0	0	0	0	0	0	0	0	0	0
##		0	0	0	0	0	0	0	0	0	0	0	0	0
##		0	0	0	0	0	0	0	0	0	0	0	0	0
##	6	0	0	0	0	0	0	0	0	0	0	0	0	0
##						V14.S								
##		0	0	0	0	0	0	0	0	1	0	0	0	0
## ##		0	0	0	0	0	1	0 1	0	0	0	0	0	0
##		0	0	0	0	1	0	0	0	0	0	0	0	0
##		0	0	0	0	1	0	0	0	0	0	0	0	0
##		0	0	0	1	0	0	0	0	0	0	0	0	0
##	•					V15.K								
##	1	0	0	0	0	0	0	0	0	0	0	0	0	0
##	2	0	0	0	0	0	0	0	0	0	0	0	0	0

```
## 3
## 4
          0
                  0
                                0
                                        0
                                               0
                                                      0
                                                              1
                                                                     0
                                                                             0
                                                                                    0
                                                                                           0
                                                                                                   0
                         0
## 5
                                                                     0
## 6
           0
                  0
                         0
                                0
                                        0
                                                       0
                                                              0
                                                                             0
                                                                                    0
                                                                                           0
                                                                                                   0
                                               1
##
      V15.V
             V15.W
                    V15.Y V16.A V16.C
                                          V16.D
                                                 V16.E V16.F
                                                                V16.G V16.H V16.I V16.K
                  0
                                        0
                                                       0
                                                              0
## 1
                         0
                                0
                                                                     0
                                                                             0
## 2
           1
                  0
                         0
                                0
                                        0
                                               0
                                                       0
                                                              0
                                                                     0
                                                                                    0
                                                                                           0
                                                                             0
## 3
           0
                  0
                         0
                                0
                                        0
                                               0
                                                      0
                                                              0
                                                                     0
                                                                             0
                                                                                    0
                                                                                           0
                                                                                                   0
## 4
           0
                  0
                         0
                                0
                                        0
                                               0
                                                      0
                                                              0
                                                                     0
                                                                             0
                                                                                           1
                                                                                                   0
## 5
           0
                  0
                         0
                                0
                                        0
                                                       0
                                                              0
                                                                     0
                                               1
                                                                             0
## 6
           0
                  0
                         0
                                        0
                                               0
                                                       0
                                                              0
                                                                     1
                                                                             0
##
      V16.M V16.N V16.P
                           V16.Q
                                   V16.R V16.S
                                                 V16.T
                                                         V16.V V16.W
                                                                       V16.Y V17.A V17.C V17.D
## 1
           0
                  0
                         0
                                0
                                        0
                                               0
                                                       0
                                                              0
                                                                     0
                                                                             0
                                                                                    0
## 2
           0
                  0
                                0
                                        0
                                               0
                                                       0
                                                              0
                                                                     0
                                                                                    0
                                                                                           0
                                                                                                   0
                         0
                                                                             0
## 3
           0
                  0
                                0
                                        0
                                               0
                                                      0
                                                              0
                                                                     0
                                                                             0
                                                                                    0
                                                                                           0
                                                                                                   0
                         1
## 4
           0
                  0
                                0
                                        0
                                               0
                                                      0
                                                              0
                                                                     0
                                                                                           0
                                                                                                   0
## 5
           0
                  0
                         0
                                0
                                        0
                                               0
                                                      0
                                                              0
                                                                     0
                                                                             0
## 6
           0
                  0
                                        0
                                               0
                                                                     0
##
      V17.E V17.F V17.G V17.H V17.I V17.K V17.L V17.M V17.N
                                                                       V17.P V17.Q V17.R V17.S
## 1
           0
                  0
                         0
                                0
                                        0
                                               0
                                                       0
                                                              0
                                                                     0
                                                                             1
## 2
          0
                  1
                         0
                                0
                                        0
                                               0
                                                      0
                                                              0
                                                                     0
                                                                             0
                                                                                    0
                                                                                           0
                                                                                                   0
## 3
           0
                  0
                                        0
                                               0
                                                              0
                                                                     0
                                                                             0
                                                                                           0
                         1
## 4
           0
                  0
                                        0
                                               0
                                                      0
                                                              0
                                                                     0
                                                                                    0
                                                                                           0
                                                                                                  0
                         1
                                0
                                                                            0
## 5
                  0
                                0
                                        0
                                               0
                                                      0
                                                              0
                                                                     0
                                                                             0
                                                                                                   1
## 6
           0
                  0
                                        0
                                               0
                                                      0
                                                              0
                                                                     0
                                                                             0
                                                                                           0
                                                                                                   0
                         0
                                0
      V17.T V17.V V17.W V17.Y
## 1
          0
                  0
                         0
                                0
##
          0
                  0
                                0
                         0
## 3
          0
                  0
                         0
                                0
## 4
           0
                  0
                         0
                                0
## 5
           0
                  0
                         0
                                0
## 6
           0
                  0
                         0
                                0
```

```
datos$V18<-factor(datos$V18,levels=c("h","e","_"),
labels=c("a_helix","b_sheet","coil"))</pre>
```

Ahora pruebo con la funcion one\_hote

```
One_hot_data = one_hot(as.data.table(datos2))
##Puedo observar que las 2 funciones funcionan perfectamente, como hay varias formas de hacer el ejerci
```

3. Desarrollar un script en R que implemente un clasificador knn. El script debe realizar los siguientes apartados:

(a) Leer el fichero data4.csv. Cada registro contiene una secuencia de 17 aminoácidos y la clase de estructura secundaria correspondiente al aminoácido central (posición 9), donde los caracteres 'h', 'e' y '\_' representan -helix, -sheet y coil, respectivamente. Después de cargar los datos, crear una tabla donde se muestre el número de secuencias de cada clase.

Vuelvo a importar el csv data4.csv, ya que al crear la funcion con dummy y one hot he podido comprobar que funciona y las variables se transofrman en 1 y 0 según donde cae el aminoacido

```
datos <- read.csv("C:\\Users\\crist\\OneDrive\\Desktop\\machine learning\\Pec 1 Cris\\data4 .csv", head</pre>
```

Haggo la tabla donde los caracterea sean -helis, -sheet, -coil, lo hare de dos formasm una centrandome en la posicion 9 y otra sin centrarme en ellos

```
datos$V18<-factor(datos$V18,levels=c("h","e","_"),
labels=c("a_helix","b_sheet","coil"))
table(factor(datos$V18), factor(datos$V9))</pre>
```

```
##
##
                Α
                                          Η
                                               Ι
                                                   K
                                                       L
                                                            М
                                                                             R.
##
     a helix 296
                   33 151 160 145 100
                                         49 119 255 265
                                                           40 105
                                                                   59
                                                                        88 108 127
##
     b_sheet 116
                   47
                       52
                            46
                                98 111
                                         26 160
                                                  86 218
                                                          39
                                                               43
                                                                   49
                                                                            55 144 167
                                                                        67
              456 111 405 256 154 747 127 222 337 376
##
                                                          67 309 355 172 151 494 286
##
##
                         Y
##
     a_helix 190
                   34
                       95
##
     b sheet 276
                   51
                       84
     coil
              301
                   66 165
```

##Como podemos ver he creado una tabla en la que me encuentro los 17 aminoacidos en su estructura secu ##hare otra tabla diferente tambien

Ahora hago la tabla sin centrarme en la columna V9

```
table(datos$V18)
```

```
## ## a_helix b_sheet coil
## 2508 1935 5557
```

Lo que puedo observar, es que tenemos 5557 que son coil, 1935 que son sheet, y 2508 que son helix.

##(b) Utilizar la función de codificación "one-hot" para representar las secuencias NOTA: En casode no poder hacer la función, se puede descargar el fichero oh enc.csv con las secuencias ya transformados

```
##quito la columna V18 para poder codificar lo datos
datos2 <- datos[-18]
data.dummy <- dummy.data.frame(datos2, sep=".")
One_hot_data = one_hot(as.data.table(datos2))
##Al tener los datos codificados, ya puedo ponerme con el apartado 3, donde hare el training y el test</pre>
```

Creo la funcion One\_hote\_data, en todo momento estoy siguiendo el libro

```
One_hot_data_label<-cbind(One_hot_data,datos$V18)
data.dummy.label <- cbind(data.dummy,datos$V18)</pre>
```

## (c) Utilizando la semilla aleatoria 123, separar los datos en dos partes, una parte para training (67%) y una parte para test (33%).

Voy a eparar los datos de 2 formas con dummy y con one-hot, para seguir asegurandome que todo funciona correctamente.

Primero lo hago con la funcion One\_hote\_data\_label

```
library(purrr)
library(caret)

##
## ## Attaching package: 'caret'

## The following object is masked from 'package:purrr':
##
## lift

set.seed(123)
ind <- sample(1:nrow(One_hot_data_label),round(2*nrow(One_hot_data_label)/3))
training_one_hot <-One_hot_data_label[ind]
test_one_hot <- One_hot_data_label[-ind,]</pre>
```

Compruebo en que he creado el training y el testing

```
dim(training_one_hot)

## [1] 6667 341

dim(test_one_hot)

## [1] 3333 341
```

Ahora hago lo mismo con la función dummy, ya que me gusta ver que podemos resolver la PEC de varias formas

```
library(caret)
set.seed(123)
ind <- sample(1:nrow(data.dummy.label),round(2*nrow(data.dummy.label)/3))
training_dummy <-data.dummy.label[ind,]
test_dummy <- data.dummy[-ind,]</pre>
```

Compruebo con la funcion dim que se dividio mi dummy en 67% de training y 33 % de test

```
dim(training_dummy)

## [1] 6667 341

dim(test_dummy)

## [1] 3333 340
```

##Como puedo ver al ver la longitud de training y test con la funcion dummy veo que la funcion test tie.

## (d) Utilizar un knn (k = 1, 3, 5, 7, 11) basado en el training para predecir la estructura secundaria de las secuencias del test.

Mientras estuve haciendo la Pec me encontre problemas con el vector que contienen las etiquetas,lo que tengo que hacer es pasarlo a factor, seguire haciendolo todo tanto en onehot como en dummy

```
head(training_one_hot$V2)
```

```
## [1] coil a_helix coil a_helix coil
## Levels: a_helix b_sheet coil
```

Convierto a integer el vector de las etiquetas de one-hot

```
training_one_hot$V2<-as.integer(training_one_hot$V2)
head(training_one_hot$V2)</pre>
```

## [1] 3 1 3 1 3 3

miro los 5 primeros valores de test\_one\_hot

head(test\_one\_hot)

```
##
      V1_A V1_C V1_D V1_E V1_F V1_G V1_H V1_I V1_K V1_L V1_M V1_N V1_P V1_Q V1_R
## 1:
          0
                0
                                       0
                                             0
                                                                    0
                                                                          0
                      0
                           0
                                 0
                                                   0
                                                        0
                                                              1
                                                                                0
                                                                                     0
                                                                                           0
## 2:
          0
                0
                      0
                                 0
                                       1
                                             0
                                                                    0
                                                                          0
                                                                                           0
## 3:
          1
                0
                      0
                           0
                                 0
                                       0
                                             0
                                                        0
                                                              0
                                                                                     0
                                                                                           0
          0
                0
                      0
                                 0
                                       0
                                             0
                                                              0
                                                                    0
                                                                          0
                                                                                           0
## 4:
                           0
                                                        1
## 5:
          0
                0
                      1
                           0
                                 0
                                       0
                                             0
                                                        0
                                                              0
                                                                    0
                                                                          0
                                                                                           0
## 6:
          0
                0
                           0
                                 0
                                       0
                                             0
                                                        0
                                                              0
                                                                    0
                                                                          0
                                                                                           0
      V1_S V1_T V1_V V1_W V1_Y V2_A V2_C V2_D V2_E V2_F V2_G V2_H V2_I V2_K V2_L
##
## 1:
          0
                0
                      0
                                       0
                                             0
                                                                    0
                                                                          0
                           0
                                                        0
                                                                                           1
                                       0
## 2:
          0
                0
                                 0
                                             0
                                                   0
                                                              0
                                                                    0
                                                                          0
                                                                                0
                                                                                     0
                                                                                           0
                      0
                           0
                                                        0
## 3:
                           0
                                 0
                                       0
                                                        0
                                                              0
                                                                                           0
                                 0
                                       0
## 4:
          0
                0
                     0
                           0
                                             0
                                                   0
                                                        0
                                                              0
                                                                    0
                                                                          0
                                                                                     0
                                                                                           0
## 5:
          0
                0
                                 0
                                       0
                                             0
                                                                          0
                                                                                           0
## 6:
          0
                0
                      0
                           0
                                 0
                                       0
                                             0
                                                   0
                                                        0
                                                              0
                                                                    0
                                                                          0
                                                                                     0
                                                                                           0
      V2_M V2_N V2_P V2_Q V2_R V2_S V2_T V2_V V2_W V2_Y V3_A V3_C V3_D V3_E V3_F
## 1:
                0
                      0
                                 0
                                       0
                                             0
                                                   0
                           0
                                                        0
```

```
## 2:
          0
                           1
                                 0
                                      0
                                            0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                                    0
                                                                                          0
## 3:
          0
                0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                                    0
                                                                                          0
                           1
## 4:
                                 0
                                      0
                                            0
                                                             0
                                                                   0
                                                                         0
                                                                                          0
                                 0
                                      0
                                                             0
## 5:
          0
                0
                     0
                           0
                                            0
                                                  0
                                                        0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
## 6:
                0
                     0
                           0
                                 0
                                      0
                                            1
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                                          0
##
      V3 G V3 H V3 I V3 K V3 L V3 M V3 N V3 P V3 Q V3 R V3 S V3 T V3 V V3 W V3 Y
## 1:
          0
                0
                                 0
                                      0
                                            0
                                                             0
                                                                   0
                                                                         0
                     0
                           0
                                                  0
                                                       1
## 2:
          0
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          1
## 3:
          1
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
## 4:
                                 0
                                      0
                                                             0
                                                                   0
                                                                         0
                                                                                    0
                                                                                          0
          0
                0
                     0
                           1
                                            0
                                                  0
                                                        0
## 5:
          0
                                 0
                                                        0
                                                             0
                                                                         1
                                                                                          0
## 6:
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                             0
                                                                   0
                                                                         0
                                                                                          0
          1
                                                        0
                                                                              0
                                                                                    0
       V4_A V4_C V4_D V4_E V4_F V4_G V4_H V4_I V4_K V4_L V4_M V4_N V4_P V4_Q V4_R
##
## 1:
          0
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                                    0
                                                                                          0
## 2:
          1
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
## 3:
          0
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          1
## 4:
          1
                0
                     0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                                    0
                                                                                          0
                           0
                                                                              0
## 5:
                                 0
                                      0
                                            0
                                                             0
                                                                   0
                                                                                          0
## 6:
          0
                0
                                 0
                                      0
                                            0
                                                             0
                                                                   0
                                                                         0
                     0
                           0
                                                  0
                                                        0
                                                                              0
                                                                                    0
                                                                                          0
##
      V4_S V4_T V4_V V4_W V4_Y V5_A V5_C V5_D V5_E V5_F V5_G V5_H V5_I V5_K V5_L
## 1:
        Ο
                Λ
                     Λ
                           Λ
                                 1
                                      0
                                            Λ
                                                  Λ
                                                       Λ
                                                             Λ
                                                                   0
                                                                         0
                                                                              0
                                                                                    Ω
                                                                                          Λ
## 2:
          0
                0
                                 0
                                      0
                                            0
                                                  0
                                                             0
                                                                   0
                                                                         0
                                                                                          0
## 3:
          0
                                 0
                                      0
                                                             0
                                                                   0
                                                                                          0
                0
                     0
                           0
                                            0
                                                  0
                                                        0
                                                                         0
                                                                              0
                                                                                    0
## 4:
          0
                0
                                 0
                                      0
                                            0
                                                  0
                                                             1
                                                                   0
                                                                         0
                                                                                          0
                     0
                           0
                                                        0
                                                                                    0
## 5:
                0
                                 0
                                      1
                                                             0
                                                                   0
          1
                     0
                           0
                                            0
                                                  0
                                                        0
                                                                                          0
## 6:
          0
                1
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
##
       V5_M V5_N V5_P V5_Q V5_R V5_S V5_T V5_V V5_W V5_Y V6_A V6_C V6_D V6_E V6_F
## 1:
         0
                0
                                 0
                                      0
                                            0
                                                                   0
                     0
                           0
                                                  0
                                                        0
                                                             1
                                                                         0
                                                                                    0
                                                                                          0
## 2:
          0
                0
                                 0
                                      0
                                            0
                                                             0
                                                                   0
                                                                         0
                     0
                           0
                                                  1
                                                        0
                                                                                    0
                                                                                          0
## 3:
          0
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             1
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
## 4:
          0
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
## 5:
          0
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   1
                                                                         0
                                                                                    0
                                                                                          0
## 6:
          0
                0
                     0
                           0
                                 0
                                      0
                                            1
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                                          0
       V6_G V6_H V6_I V6_K V6_L V6_M V6_N V6_P V6_Q V6_R V6_S V6_T V6_V V6_W V6_Y
##
## 1:
         1
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                                    0
## 2:
         0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                             0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
                1
                                                        0
## 3:
          0
                0
                     0
                                 1
                                      0
                                            0
                                                  0
                                                             0
                                                                   0
                                                                         0
                                                                                          0
## 4:
          0
                0
                     0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
                           1
## 5:
          0
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                                          0
                0
                                      0
                                                                   0
## 6:
          Λ
                     0
                           0
                                 0
                                            0
                                                  0
                                                        0
                                                             0
                                                                         0
                                                                                    0
                                                                                          0
                                                                              1
       V7_A V7_C V7_D V7_E V7_F V7_G V7_H V7_I V7_K V7_L V7_M V7_N V7_P V7_Q V7_R
## 1:
         0
                0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                             0
                                                                         0
                                                                                          0
                     0
                                                        0
                                                                   1
                                                                              0
                                                                                    0
## 2:
          0
                0
                                 0
                                            0
                                                             0
                                                                   0
                                                                         0
                     0
                           0
                                      1
                                                  0
                                                        0
                                                                              0
                                                                                    0
                                                                                          0
## 3:
          0
                0
                                 0
                                            0
                                                             0
                                                                   0
                                                                         0
                                                                                    0
                                                                                          0
                     0
                           0
                                      1
                                                  0
                                                        0
## 4:
                     0
                                 0
                                            0
                                                             0
                           0
                                                  0
                                                        1
                                                                                          0
                                 0
                                      0
## 5:
          0
                0
                     0
                           0
                                            0
                                                  0
                                                             0
                                                                   0
                                                                              0
                                                                                          0
                                                        0
                                                                         1
                                                                                    0
          0
                                 0
                                      0
                                            0
                                                                   0
## 6:
                0
                     0
                           0
                                                  0
                                                        0
                                                             1
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
       V7_S V7_T V7_V V7_W V7_Y V8_A V8_C V8_D V8_E V8_F V8_G V8_H V8_I V8_K V8_L
##
## 1:
         0
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
## 2:
          0
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
## 3:
          0
                0
                     0
                           0
                                 0
                                      0
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                                    0
                                                                                          0
                0
                     0
                                 0
                                            0
                                                             0
                                                                   0
## 4:
          0
                           0
                                      1
                                                  0
                                                        0
                                                                         0
                                                                                    0
                                                                                          0
## 5:
          0
                0
                     0
                           0
                                 0
                                      1
                                            0
                                                  0
                                                        0
                                                             0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
## 6:
                0
                     0
                                 0
                                      0
                                            0
                                                             0
         0
                           0
                                                  0
                                                        0
                                                                   0
                                                                         0
                                                                              0
                                                                                    0
                                                                                          0
```

```
V8_M V8_N V8_P V8_Q V8_R V8_S V8_T V8_V V8_W V8_Y V9_A V9_C V9_D V9_E V9_F
## 1:
          0
                0
                      0
                           0
                                 0
                                       0
                                                  0
                                                        0
                                                              0
                                                                    0
                                                                          0
                                                                               0
                                             1
                                                                                     1
## 2:
                                             0
          0
                0
                      0
                           0
                                 0
                                       0
                                                   1
                                                              0
                                                                    0
                                                                          0
                                                                                           0
## 3:
          0
                0
                                 0
                                       0
                                                              0
                                                                    0
                                                                          0
                                                                                     0
                                                                                           0
                      0
                           0
                                             1
                                                   0
                                                        0
                                                                               0
## 4:
          0
                0
                      0
                           0
                                 0
                                       0
                                             0
                                                   0
                                                        0
                                                              0
                                                                    0
                                                                          0
                                                                                     0
                                                                                           0
## 5:
          Ω
                      0
                           Λ
                                 0
                                       0
                                             Λ
                                                   0
                                                        Λ
                                                              0
                                                                    0
                                                                          0
                                                                                     0
                                                                                           0
                           0
                                 0
                                       0
                                             0
                                                  0
                                                        0
                                                              1
                                                                    0
                                                                          0
       V9 G V9 H V9 I V9 K V9 L V9 M V9 N V9 P V9 Q V9 R V9 S V9 T V9 V V9 W V9 Y
##
## 1:
          0
                0
                      0
                           0
                                 0
                                       0
                                             0
                                                   0
                                                        0
                                                              0
                                                                    0
                                                                          0
                                                                               0
                                                                                     0
## 2:
          0
                0
                      0
                                 0
                                       0
                                             0
                                                   0
                                                              0
                                                                    0
                                                                               0
                                                                                     0
                                                                                           0
                           0
                                                        0
                                                                          1
## 3:
          0
                0
                      0
                           0
                                 0
                                       0
                                             0
                                                   0
                                                        1
                                                              0
                                                                    0
                                                                          0
                                                                                           0
                                 0
                                       0
                                             0
                                                              0
                                                                    0
                                                                                           0
## 4:
          0
                0
                      0
                                                   0
                                                        0
                                                                          0
                                                                               0
                                                                                     0
                           1
                                 0
                                       0
                                                              0
                                                                    0
                                                                                           0
## 5:
          0
                0
                      0
                           0
                                             0
                                                   0
                                                        0
                                                                          1
                                                                                     0
                           0
                                       0
                                             0
                                                              0
                                                                    0
                                                                          0
## 6:
                0
                      0
                                 1
                                                  0
                                                        0
       V10_A V10_C V10_D V10_E V10_F V10_G V10_H V10_I V10_K V10_L V10_M V10_N
## 1:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                 1
## 2:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                 0
                                                                                       0
                                                                                       0
## 3:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                                          0
## 4:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                          0
                                                                                       0
                                                                   1
## 5:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                       0
## 6:
           Λ
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                       0
      V10_P V10_Q V10_R V10_S V10_T V10_V V10_W V10_Y V11_A V11_C V11_D V11_E
## 1:
                         0
                                       0
                                                                                 0
           0
                  0
                                0
                                              Ω
                                                     0
                                                            0
                                                                   0
                                                                         Λ
                                                                                       0
## 2:
           0
                  0
                         0
                                1
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                 0
                                                                                       0
## 3:
                         0
                                0
                                       0
                                              0
                                                                   0
                                                                          0
                                                                                 0
                                                                                       1
           1
                  0
                                                     0
                                                            0
## 4:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                                                       0
## 5:
           0
                  0
                         0
                                0
                                       0
                                              1
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                 0
                                                                                       0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
           1
       V11_F V11_G V11_H V11_I V11_K V11_L V11_M V11_N V11_P V11_Q V11_R V11_S
                  0
                         0
                                       0
                                              0
## 1:
           0
                                0
                                                     0
                                                            1
                                                                   0
                                                                          0
                                                                                       0
## 2:
           1
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                 0
                                                                                       0
## 3:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                 0
                                                                                       0
                         0
                                                                                       0
## 4:
           0
                  0
                                0
                                       1
                                              0
                                                     0
                                                            0
## 5:
           0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                       0
                  1
## 6:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                           0
                                                                  0
                                                                          0
                                                                                 0
      V11_T V11_V V11_W V11_Y V12_A V12_C V12_D V12_E V12_F V12_G V12_H V12_I
##
## 1:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                 0
                                                                                       0
## 2:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                 0
                                                                                       0
## 3:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                 0
                                                                                       0
                         0
                                0
                                       0
                                              0
                                                                                       0
## 4:
           0
                  Λ
                                                     Λ
                                                            Λ
                                                                   0
                                                                                 0
## 5:
                         0
                                0
                                       0
                                              0
                                                     0
## 6:
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                           0
                                                                  0
                                                                         0
                                                                                 0
                                                                                       0
           1
       V12_K V12_L V12_M V12_N V12_P V12_Q V12_R V12_S V12_T V12_V V12_W V12_Y
##
## 1:
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          Λ
                                                                                 Λ
           0
                                                                                       1
## 2:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          1
                                                                                 0
                                                                                       0
## 3:
           0
                  0
                         0
                                0
                                       1
                                              0
                                                     0
                                                                   0
                                                                          0
                                                            0
                         0
                                       0
                                              0
## 4:
           0
                  0
                                0
                                                     0
                                                            0
                                                                          1
                                                                                       0
## 5:
                                       0
                                              0
                                                                                       0
           0
                         1
                                                     0
                                                            0
## 6:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            1
                                                                   0
                                                                          0
                                                                                 0
                                                                                       0
       V13_A V13_C V13_D V13_E V13_F V13_G V13_H V13_I V13_K V13_L V13_M V13_N
##
## 1:
           0
                  0
                         0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                 0
                                                                                       0
                         0
## 2:
                  0
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                 0
                                                                                       0
           0
## 3:
           0
                  0
                         1
                                0
                                       0
                                              0
                                                     0
                                                            0
                                                                   0
                                                                          0
                                                                                 0
                                                                                       0
                         0
                                       0
## 4:
           0
                  0
                                0
                                              0
                                                     0
                                                            0
                                                                   1
                                                                          0
                                                                                 0
                                                                                       0
```

```
0
                                   0
                                          0
                                                 0
          1
                0
                       0
                                                       0
                                                              0
                                                                     0
                                                                           0
## 6:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
                                                                                  0
      V13 P V13 Q V13 R V13 S V13 T V13 V V13 W V13 Y V14 A V14 C V14 D V14 E
                       0
                              0
                                    0
                                           0
                                                 0
                                                              0
                                                                     0
                                                                           0
## 1:
          0
                 0
                                                        1
                                                                                  0
## 2:
          0
                 0
                       0
                              1
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
                                                                                  0
## 3:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              1
                                                                     0
                                                                           0
                                                                                  0
## 4:
          0
                       0
                              0
                                    0
                                           0
                                                 0
                                                                     0
## 5:
                       0
                              0
                                    0
                                           0
          0
                 0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
## 6:
          0
                 0
                       0
                              0
                                    0
                                           1
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
      V14_F V14_G V14_H V14_I V14_K V14_L V14_M V14_N V14_P V14_Q V14_R V14_S
##
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                       0
                              0
                                    0
                                           0
                                                                     0
                                                                                  0
## 2:
          0
                 0
                                                 0
                                                        0
                                                              0
                                                                           1
## 3:
                       0
                              0
                                    0
                                           0
                                                              0
                                                                     0
                                                                           0
                                                                                  0
          0
                 0
                                                 0
                                                        0
                       0
## 4:
          0
                 0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
## 5:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
## 6:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
##
      V14_T V14_V V14_W V14_Y V15_A V15_C V15_D V15_E V15_F V15_G V15_H V15_I
          1
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
## 2:
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
                                                                                  0
          0
## 3:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
                                                                                  0
## 4:
          0
                 0
                       0
                              0
                                    1
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
                                                                                  0
## 5:
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
## 6:
          0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
                 1
      V15 K V15 L V15 M V15 N V15 P V15 Q V15 R V15 S V15 T V15 V V15 W V15 Y
                 0
                       0
                                    0
                                                 0
                                                        0
## 1:
          0
                              0
                                           0
                                                              0
                                                                     1
                                                                           Ω
## 2:
          0
                 1
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
## 3:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     1
                                                                           0
                                                                                  0
## 4:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
                                                                                  0
## 5:
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                                     0
          0
                                                              1
                       0
                              0
                                    0
                                           0
                                                 0
## 6:
          0
                 0
                                                        1
                                                              0
      V16_A V16_C V16_D V16_E V16_F V16_G V16_H V16_I V16_K V16_L V16_M V16_N
##
## 1:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     1
                                                                           0
                 0
                       0
                                    0
                                                              0
                                                                     0
                                                                           0
## 2:
          0
                              0
                                           1
                                                 0
                                                        0
## 3:
          0
                 0
                       0
                              0
                                    0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
                                                                                  0
                                           1
## 4:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                                     0
                                                                           0
                                                                                  0
## 5:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                                     0
                                                                                  0
## 6:
          1
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
##
      V16_P V16_Q V16_R V16_S V16_T V16_V V16_W V16_Y V17_A V17_C V17_D V17_E
## 1:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
                                    0
                                                                           0
                                                                                  0
## 2:
          0
                 0
                       0
                              0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     1
## 3:
          0
                       0
                                    0
                                           0
                                                 0
                                                                     0
                                                                                  0
## 4:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
                                                                                  0
## 5:
                 0
                       1
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                                  0
          0
## 6:
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
          0
      V17_F V17_G V17_H V17_I V17_K V17_L V17_M V17_N V17_P V17_Q V17_R V17_S
## 1:
                       0
                              0
                                    0
                                           0
                                                                           0
                 0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                                  0
          1
                       0
                                    0
                                           0
                                                                     0
                                                                           0
                                                                                  0
## 2:
          0
                 0
                              0
                                                 0
                                                        0
                                                              0
## 3:
                 0
                       0
                              0
                                    0
                                                              0
                                                                     0
                                                                           0
                                                                                  0
          0
                                           1
                                                 0
                                                        0
## 4:
          0
                 0
                       0
                              0
                                    1
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
                                                                                  0
## 5:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           1
                                                                                  0
## 6:
          0
                 0
                       0
                              0
                                    0
                                           0
                                                 0
                                                        0
                                                              0
                                                                     0
                                                                           0
                                                                                  0
      V17_T V17_V V17_W V17_Y
                                   ٧2
##
## 1:
          0
                 0
                       0 0
                                   coil
## 2:
                       0
          0
                 0
                            0 b sheet
```

```
## 3: 0 0 0 0 coil
## 4: 0 0 0 0 a_helix
## 5: 0 0 0 0 coil
## 6: 0 0 0 1 b_sheet
```

Paso el vector a integer, para no tener problemas al realizar los knn vecinos cercanos

```
test_one_hot$V2<-as.integer(test_one_hot$V2)
head(test_one_hot$V2)

## [1] 3 2 3 1 3 2

table(training_one_hot$V2)

##
## 1 2 3
## 1668 1282 3717

table(test_one_hot$V2)

##
## 1 2 3
## 840 653 1840</pre>
```

(d) Utilizar un knn (k = 1, 3, 5, 7, 11) basado en el training para predecir la estructura secundaria de las secuencias del test.

Vamos a hacer los KNN los vecinos cercanos con los datos que hemos separado en el apartado anterior

#### K1

```
library(class)
library(gmodels)
predicion1<-knn(train=training_one_hot, test=test_one_hot,
cl=training_one_hot$V2, k=1)
k1<-CrossTable(x=test_one_hot$V2, y=predicion1,
prop.chisq = FALSE)</pre>
```

```
##
##
##
    Cell Contents
## |-----|
## |
           N / Row Total |
## |
## |
           N / Col Total |
## |
         N / Table Total |
## |-----|
##
##
## Total Observations in Table: 3333
```

## ## ## | predicion1 ## test\_one\_hot\$V2 | 1 | 2 | 3 | Row Total | ## -----|----|-----| 766 | 60 | 14 | ## 1 | 0.912 | 0.071 | 0.017 | 0.954 | 0.088 | 0.008 | - 1 ## 0.018 0.004 | 0.230 l 32 | 2 | 519 | 102 | 0.049 | ## 0.795 | 0.156 | 0.196 | 0.040 | ## - 1 0.759 | 0.055 | 0.010 0.156 0.031 5 | 1730 | 105 | 3 | 1840 l ## 1 0.003 | 0.057 | 0.940 | 0.552 | 0.006 | 0.154 | 0.937 | 0.002 | 0.032 | 0.519 l ## -----|----|-----|-----|-----| Column Total | 803 | 684 | ## 1846 | 3333 I 0.241 | 0.205 | 0.554 | -----|----|-----| ##

#### Ahora hago el k3

```
predicion3<-knn(train=training_one_hot, test=test_one_hot,
    cl=training_one_hot$V2, k=3)
k1<-CrossTable(x=test_one_hot$V2, y=predicion3,
    prop.chisq = FALSE)</pre>
```

```
##
##
##
    Cell Contents
## |
           N I
## |
         N / Row Total |
         N / Col Total |
## |
        N / Table Total |
##
##
## Total Observations in Table: 3333
##
##
##
      | predicion3
## test_one_hot$V2 | 1 |
                            2 | 3 | Row Total |
## -----|----|-----|
                 769 | 63 | 8 | 840 |
##
            1 |
              | 0.915 | 0.075 | 0.010 |
| 0.942 | 0.105 | 0.004 |
##
             0.252 |
##
```

```
| 0.231 | 0.019 | 0.002 |
         -----|----|-----|-----|
                        442 | 166 | 653 |
            0.069 |
                        0.677 |
##
                                0.254 |
                                         0.196 |
            0.055 |
                        0.734 |
                                0.087 |
                0.014 |
                        0.133 | 0.050 |
                        97 l
                                1741 |
                   2 |
           3 I
                0.001 | 0.053 |
                              0.946 l
##
           - 1
                                         0.552 l
                                0.909 |
##
               0.002 |
                        0.161 |
                0.001 |
                        0.029 |
                                0.522 |
##
    Column Total | 816 |
                        602 |
                                 1915 |
                                         3333 l
                0.245 | 0.181 | 0.575 |
         ----|-----|-----|
##
##
```

k5

```
predicion5<-knn(train=training_one_hot, test=test_one_hot,
    cl=training_one_hot$V2, k=5)
k1<-CrossTable(x=test_one_hot$V2, y=predicion5,
    prop.chisq = FALSE)</pre>
```

```
##
##
    Cell Contents
## |
         N / Row Total |
N / Col Total |
## |
        N / Table Total |
##
## Total Observations in Table: 3333
##
##
##
         | predicion5
## test_one_hot$V2 | 1 |
                              2 | 3 | Row Total |
                 -----|-----|------|
                          76 |
                                   6 l
                 758 |
            1 |
                                              840
                          0.090 |
##
                                    0.007 |
             0.902 |
                           0.136 l
##
              0.940 l
                                    0.003 l
                            0.023 |
                                     0.002 |
                   0.227
                   47 |
                                     215 |
            2 |
                            391 |
                                               653 |
##
             0.072 |
                         0.599 | 0.329 |
##
                                              0.196 I
##
                  0.058 |
                           0.701 | 0.109 |
            | 0.014 | 0.117 | 0.065 |
            ---|------|-----|-----|-----|---
            3 | 1 | 91 | 1748 | 1840 |
##
```

```
0.001 | 0.049 | 0.950 |
##
##
                 0.001 |
                         0.163 |
                                  0.888 l
                 0.000 |
                         0.027 |
##
                                   0.524
##
    Column Total |
##
                  806 |
                          558 |
                                   1969 |
##
                 0.242 | 0.167 |
                                  0.591 |
         |
     -----|----|-----|
##
##
k7
predicion7<-knn(train=training_one_hot, test=test_one_hot,</pre>
cl=training_one_hot$V2, k=7)
k1<-CrossTable(x=test_one_hot$V2, y=predicion7,</pre>
prop.chisq = FALSE)
##
##
##
    Cell Contents
## |-----|
## |
        N / Row Total |
N / Col Total |
## |
## |
        N / Table Total |
## |-----|
##
##
## Total Observations in Table: 3333
##
##
##
         | predicion7
## test_one_hot$V2 | 1 |
                            2 | 3 | Row Total |
 _____|
                         90 | 5 |
           1 |
                 745 |
                                           840 |
##
##
            - 1
                 0.887 |
                         0.107 |
                                  0.006 |
            0.936 |
                         0.174 |
                                 0.002 |
##
                 0.224 |
                         0.027 l
                                  0.002 |
   ##
                50 |
                          348 |
##
           2 |
                                   255 |
                                           653 l
            0.077 | 0.533 | 0.391 |
##
                                           0.196 |
##
             0.063 |
                         0.672 |
                                  0.126 |
                       0.104 |
                                   0.077
##
                 0.015 |
                  -----|-----|-----|-
                1 |
                       80 |
            3 |
                                  1759 |
                                           1840
                                           0.552 |
                 0.001 |
                         0.043 |
                                 0.956 |
##
            ##
                 0.001 |
                         0.154 |
                                  0.871 |
                 0.000 |
                         0.024 |
##
                                   0.528 |
    Column Total | 796 | 518 |
                                  2019 |
##
                       0.155 |
##
      1
                 0.239 |
                                  0.606 |
                                          1
## -----|----|-----|
##
```

##

#### k11

```
predicion11<-knn(train=training_one_hot, test=test_one_hot,
    cl=training_one_hot$V2, k=11)
k1<-CrossTable(x=test_one_hot$V2, y=predicion11,
    prop.chisq = FALSE)</pre>
```

N   N   N   N   N   N   N   N   N   N									
Total Observation	ns in Table:	3333							
	predicion11								
test_one_hot\$V2	1	2	3	Row Total					
	-	 - · ·							
1	768	71	1	8					
	0.914	0.085	0.001	0.2					
	0.941   0.230	0.171   0.021	0.000	 					
	ı 0.∠30   	U.U21 	0.000	ı I					
2	l 48 l	300	305	l 6					
_	0.074	0.459	0.467	0.1					
	0.059	0.721	0.145						
	0.014	0.090	0.092	<u> </u>					
3	-   0	   45	1795	   18					
	0.000	0.024	0.976	0.5					
	0.000	0.108	0.854						
	0.000	0.014	0.539	  -					
Column Total	-   816	416	2101	   33					
	0.245	0.125	0.630						

##(e) Por otra parte, sabemos que las clases -helix y -sheet son del tipo non-coil. Realizar otro knn (k = 1, 3, 5, 7, 11) para esta nueva clasificación, coil y non-coil. Además, realizar una curva ROC para cada k y calcular su área bajo la curva (AUC).

## library(car)

## Loading required package: carData

<sup>\*\*</sup>Haremos el mismo proceso que en apartado anterior, pero diferenciaremos entre las que no son coil

```
##
## Attaching package: 'car'
## The following object is masked from 'package:dplyr':
##
##
       recode
## The following object is masked from 'package:purrr':
##
##
       some
training_one_hot$coil <- recode(training_one_hot$V2,"1:2=0; 3=1")</pre>
test_one_hot$coil <- recode(test_one_hot$V2, "1:2=0; 3=1")</pre>
table(training_one_hot$coil)
##
##
      0
## 2950 3717
table(test_one_hot$coil)
##
##
      0
           1
## 1493 1840
```

Vamos a realizar el knn para (1,3,5,7,11), pero lo haremos en los datos coil, el apartado será muy parecido al anterior, pero usaremos lo s datos coil

```
library(class)
library(gmodels)
predicion_coil_1 <-knn(train=training_one_hot, test=test_one_hot,
cl=training_one_hot$coil, k=1)
predicion_coil_3 <-knn(train=training_one_hot, test=test_one_hot,
cl=training_one_hot$coil, k=3)
predicion_coil_5 <-knn(train=training_one_hot, test=test_one_hot,
cl=training_one_hot$coil, k=5)
predicion_coil_7 <-knn(train=training_one_hot, test=test_one_hot,
cl=training_one_hot$coil, k=7)
predicion_coil_11 <-knn(train=training_one_hot, test=test_one_hot,
cl=training_one_hot$coil, k=11)</pre>
```

Tenemos que crear la curva ROC, y elAUC, para las 5 k que hemos realizado (k=1,3,5,7,11)

```
library(ROCR)
#K=1

test_predicion_1<-knn(train=training_one_hot, test=test_one_hot,cl=training_one_hot$coil, k=1,prob=T)

test_probabilidad_1<-attr(test_predicion_1,"prob")

t_1_probabilidad<-ifelse(predicion_coil_1==1,test_probabilidad_1,1-test_probabilidad_1)

test_1nc_probabilidad<-1-t_1_probabilidad

resultados_coil_1<-data.frame(test_one_hot$coil,predicion_coil_1, t_1_probabilidad,test_1nc_probabilidad
head(resultados_coil_1)</pre>
```

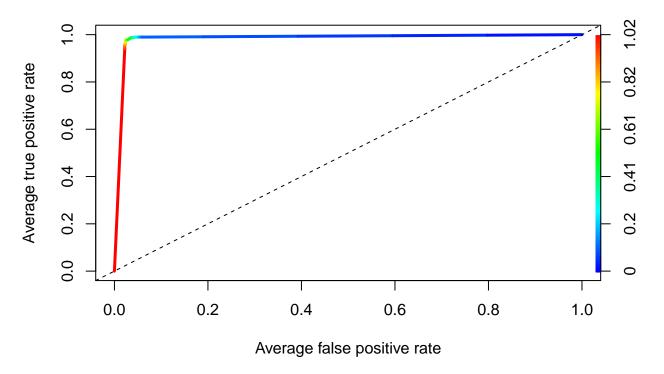
```
{\tt test\_one\_hot.coil\ predicion\_coil\_1\ t\_1\_probabilidad\ test\_1nc\_probabilidad}
##
## 1
## 2
                         0
## 3
                         1
                                              1
                                                                    1
                                                                                              0
## 4
                          0
                                                                    0
                                                                                               1
## 5
                                                                                              0
                         1
                                              1
                                                                    1
## 6
                                                                    0
                                                                                               1
```

```
library(ROCR)
prediction.k1<-prediction(predictions= resultados_coil_1$t_1_probabilidad,labels=resultados_coil_1$test_
performance1k<-performance(prediction.k1,measure="tpr",x.measure="fpr")
auc.performance1k<-performance(prediction.k1,measure="auc")
auc.performance1k<-unlist(auc.performance1k@y.values)
auc.performance1k</pre>
```

#### ## [1] 0.9828701

```
plot(performance1k,avg="threshold",colorize=T,lwd=3,
main=("Curva ROC k=1, AUC = 0.9953124"))
abline(a=0,b=1,lwd=1,lty=2)
```

## Curva ROC k=1, AUC = 0.9953124

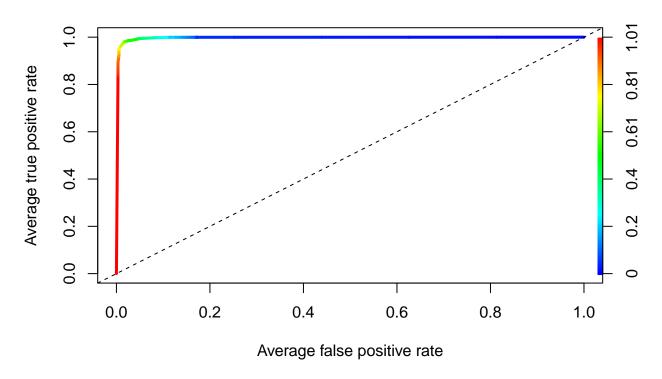


Voy ahora con los otros 4 knn que me faltan.

```
library(ROCR)
#K=3
test_predicion_3<-knn(train=training_one_hot, test=test_one_hot,cl=training_one_hot$coil, k=3,prob=T)
test_probabilidad_3<-attr(test_predicion_3,"prob")</pre>
t_3_probabilidad<-ifelse(predicion_coil_3==1,test_probabilidad_3,1-test_probabilidad_3)
test_3nc_probabilidad<-1-t_3_probabilidad
resultados_coil_3<-data.frame(test_one_hot$coil,predicion_coil_3, t_3_probabilidad,test_3nc_probabilida
head(resultados coil 3)
##
     test_one_hot.coil predicion_coil_3 t_3_probabilidad test_3nc_probabilidad
## 1
                                                 1.0000000
                                                                      0.00000000
                     1
                                       1
## 2
                     0
                                                0.0000000
                                                                      1.00000000
                                       0
## 3
                     1
                                       1
                                                1.0000000
                                                                      0.0000000
## 4
                     0
                                       0
                                                0.0000000
                                                                      1.00000000
## 5
                                       1
                                                0.9545455
                                                                      0.04545455
                     1
## 6
                                                0.0000000
                                                                       1.0000000
library(ROCR)
prediction.k3<-prediction(predictions= resultados_coil_3$t_3_probabilidad, labels=resultados_coil_3$test_
performance3k<-performance(prediction.k3,measure="tpr",x.measure="fpr")</pre>
auc.performance3k<-performance(predicion.k3,measure="auc")</pre>
auc.performance3k<-unlist(auc.performance3k@y.values)</pre>
auc.performance3k
## [1] 0.9966216
```

```
plot(performance3k,avg="threshold",colorize=T,lwd=3,
main=("Curva ROC k=3, AUC = 0.9828701"))
abline(a=0,b=1,lwd=1,lty=2)
```

### Curva ROC k=3, AUC = 0.9828701



#### k5

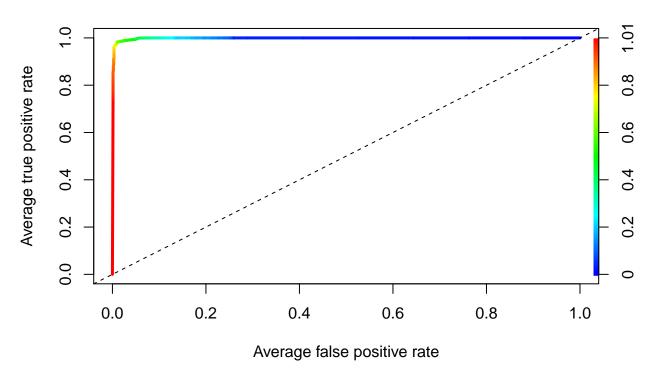
auc.performance5k

```
library(ROCR)
#K=5
test_predicion_5<-knn(train=training_one_hot, test=test_one_hot,cl=training_one_hot$coil, k=5,prob=T)
test_probabilidad_5<-attr(test_predicion_5,"prob")</pre>
t_5_probabilidad<-ifelse(predicion_coil_5==1,test_probabilidad_5,1-test_probabilidad_5)
test_5nc_probabilidad<-1-t_5_probabilidad
resultados_coil_5<-data.frame(test_one_hot$coil,predicion_coil_5, t_5_probabilidad,test_5nc_probabilida
head(resultados_coil_5)
##
     test_one_hot.coil predicion_coil_5 t_5_probabilidad test_5nc_probabilidad
## 1
                                                 1.0000000
                                                                      0.0000000
                     1
## 2
                                                                      1.0000000
                     0
                                       0
                                                0.0000000
                                                                      0.0000000
## 3
                     1
                                       1
                                                 1.0000000
                     0
                                       0
                                                                      1.0000000
## 4
                                                0.000000
## 5
                     1
                                       1
                                                 0.9545455
                                                                      0.04545455
## 6
                                                 0.2500000
                                                                      0.75000000
library(ROCR)
prediction.k5<-prediction(predictions= resultados_coil_5$t_5_probabilidad, labels=resultados_coil_5$test_
performance5k<-performance(prediction.k5,measure="tpr",x.measure="fpr")</pre>
```

auc.performance5k<-performance(predicion.k5,measure="auc")
auc.performance5k<-unlist(auc.performance5k@y.values)</pre>

```
plot(performance5k,avg="threshold",colorize=T,lwd=3,
main=("Curva ROC k=5, AUC = 0.9982655"))
abline(a=0,b=1,lwd=1,lty=2)
```

## Curva ROC k=5, AUC = 0.9982655



#### k7

```
library(ROCR)
#K=7

test_predicion_7<-knn(train=training_one_hot, test=test_one_hot,cl=training_one_hot$coil, k=7,prob=T)

test_probabilidad_7<-attr(test_predicion_7,"prob")
t_7_probabilidad<-ifelse(predicion_coil_7==1,test_probabilidad_7,1-test_probabilidad_7)

test_7nc_probabilidad<-1-t_7_probabilidad
resultados_coil_7<-data.frame(test_one_hot$coil,predicion_coil_7, t_7_probabilidad,test_7nc_probabilidad
head(resultados_coil_7)

## test_one_hot.coil predicion_coil_7 t_7_probabilidad test_7nc_probabilidad
## 1 00000000</pre>
```

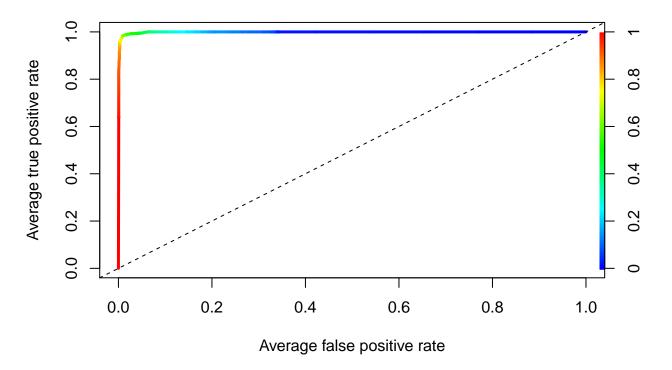
```
## 1
                                                 1.0000000
                                                                        0.0000000
## 2
                      0
                                        0
                                                 0.1000000
                                                                        0.9000000
## 3
                                                 1.0000000
                                                                        0.0000000
                      1
                                        1
                      0
                                        0
                                                 0.000000
                                                                        1.0000000
## 4
## 5
                      1
                                        1
                                                 0.9545455
                                                                        0.04545455
                      0
                                                 0.2500000
                                                                        0.75000000
## 6
```

```
library(ROCR)
prediction.k7<-prediction(predictions= resultados_coil_7$t_7_probabilidad,labels=resultados_coil_7$test_
performance7k<-performance(prediction.k7,measure="tpr",x.measure="fpr")
auc.performance7k<-performance(prediction.k7,measure="auc")
auc.performance7k<-unlist(auc.performance7k@y.values)
auc.performance7k</pre>
```

#### ## [1] 0.9987329

```
plot(performance7k,avg="threshold",colorize=T,lwd=3,
main=("Curva ROC k=7, AUC = 0.9987329"))
abline(a=0,b=1,lwd=1,lty=2)
```

### Curva ROC k=7, AUC = 0.9987329



#### k11

```
library(ROCR)
#K=11
test_predicion_11<-knn(train=training_one_hot, test=test_one_hot,cl=training_one_hot$coil, k=11,prob=T)
test_probabilidad_11<-attr(test_predicion_11,"prob")
t_11_probabilidad<-ifelse(predicion_coil_11==1,test_probabilidad_11,1-test_probabilidad_11)
test_11nc_probabilidad<-1-t_11_probabilidad
resultados_coil_11<-data.frame(test_one_hot$coil,predicion_coil_11, t_11_probabilidad,test_11nc_probabilidad(resultados_coil_11)</pre>
```

## test\_one\_hot.coil predicion\_coil\_11 t\_11\_probabilidad test\_11nc\_probabilidad

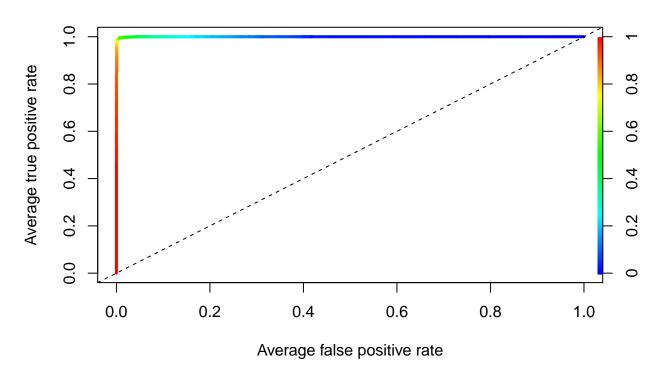
```
## 1
                      1
                                                     0.9545455
                                                                             0.04545455
## 2
                      0
                                          0
                                                     0.2500000
                                                                             0.75000000
## 3
                                          1
                                                     1.0000000
                                                                             0.0000000
                                          0
## 4
                      0
                                                     0.000000
                                                                             1.0000000
## 5
                      1
                                          1
                                                     0.9545455
                                                                             0.04545455
## 6
                                          0
                                                     0.2500000
                                                                             0.75000000
```

```
library(ROCR)
prediction.k11<-prediction(predictions= resultados_coil_11$t_11_probabilidad,labels=resultados_coil_11$t
performance11k<-performance(prediction.k11,measure="tpr",x.measure="fpr")
auc.performance11k<-performance(prediction.k11,measure="auc")
auc.performance11k<-unlist(auc.performance11k@y.values)
auc.performance11k</pre>
```

#### ## [1] 0.9997547

```
plot(performance11k,avg="threshold",colorize=T,lwd=3,
main=("Curva ROC k=11, AUC = 0.9997547"))
abline(a=0,b=1,lwd=1,lty=2)
```

## Curva ROC k=11, AUC = 0.9997547



##(f) Comentar los resultados de la clasificación para las tres clases de estructuras secundarias basado,como mínimo, en el error de clasificación y el valor de kappa. Además, comentar los resultados para las clases coil y non-coil en función del AUC, número de falsos positivos, falsos negativos y error de clasificación obtenidos para los diferentes valores de k.

```
library(caret)
Matriz_1<-CrossTable(x=test_one_hot$V2, y=predicion1,
prop.chisq = FALSE)</pre>
```

```
##
##
##
    Cell Contents
## |-----|
          N / Row Total |
N / Col Total |
## |
        N / Table Total |
## |-----|
##
##
## Total Observations in Table: 3333
##
##
##
         | predicion1
## test_one_hot$V2 | 1 |
                             2 | 3 | Row Total |
                               ----|-----|
                                              840 |
                  766 |
                           60 | 14 |
             1 |
##
                   0.912 | 0.071 |
                                      0.017 |
                                                0.252 |
##
             - 1
               1
                  0.954 |
                            0.088 |
                                     0.008
##
                   0.230 |
                            0.018 |
                                    0.004 |
             2 | 32 | 519 | 102 |
| 0.049 | 0.795 | 0.156 |
| 0.040 | 0.759 | 0.055 |
##
                                               653 |
##
                          0.156 |
              ı
                   0.010 |
                                      0.031 l
                   5 |
            3 |
##
                             105 |
                                      1730 |
                                                1840 |
                          0.057 |
                  0.003 |
             - 1
                                                0.552 |
##
                                      0.940
              0.006 |
##
                            0.154 |
                                    0.937 |
                   0.002 |
                            0.032 |
                                      0.519
                           684 |
                 803 |
                                     1846 | 3333 |
    Column Total |
##
                   0.241 | 0.205 |
##
      0.554 |
##
##
```

#### table(test\_one\_hot\$V2)

Pasamos a factor

```
test_one_hot$V2 <- factor(test_one_hot$V2, levels=c(1,2,3),</pre>
labels=c("a_helix","b_sheet","coil"))
table(test_one_hot$V2)
##
## a_helix b_sheet
                       coil
       840
                       1840
               653
predicion1 <- factor(predicion1, levels=c(1,2,3),</pre>
labels=c("a_helix","b_sheet","coil"))
table(predicion1)
## predicion1
## a_helix b_sheet
                       coil
       803
               684
                       1846
Creo la matriz de confusion, para poder obtener el valor kappa y el erro
confusionMatrix(predicion1,test_one_hot$V2, positive="non_coil")
## Confusion Matrix and Statistics
##
##
             Reference
## Prediction a_helix b_sheet coil
      a helix
                 766
##
                            32
##
      b sheet
                   60
                           519 105
      coil
                    14
                           102 1730
##
##
## Overall Statistics
##
##
                  Accuracy: 0.9046
##
                    95% CI: (0.8941, 0.9144)
       No Information Rate: 0.5521
##
##
       P-Value [Acc > NIR] : < 2.2e-16
##
##
                     Kappa: 0.8392
##
   Mcnemar's Test P-Value: 0.005023
##
##
## Statistics by Class:
##
##
                         Class: a_helix Class: b_sheet Class: coil
## Sensitivity
                                 0.9119
                                                 0.7948
                                                             0.9402
## Specificity
                                                 0.9384
                                                             0.9223
                                 0.9852
## Pos Pred Value
                                 0.9539
                                                 0.7588
                                                             0.9372
## Neg Pred Value
                                 0.9708
                                                 0.9494
                                                             0.9260
## Prevalence
                                 0.2520
                                                 0.1959
                                                             0.5521
## Detection Rate
                                 0.2298
                                                 0.1557
                                                             0.5191
## Detection Prevalence
                                 0.2409
                                                 0.2052
                                                             0.5539
## Balanced Accuracy
                                 0.9485
                                                 0.8666
                                                             0.9313
```

Calculo el error

```
print(error_1 <- 1-0.9046)</pre>
```

```
## [1] 0.0954
```

Podemos ver que el error que obtengo es de 0.0954 y estoy obteniendo un valor de kappa de 0.8392, son buenos valores, pero voy aprobar en las siguientes k=3,5,7,11

```
library(caret)
Matriz_3<-CrossTable(x=test_one_hot$V2, y=predicion3,
prop.chisq = FALSE)</pre>
```

```
##
##
    Cell Contents
   -----|
## |
## |
                   ΝI
         N / Row Total |
         N / Col Total |
## |
        N / Table Total |
  |-----|
##
##
## Total Observations in Table: 3333
##
##
##
              | predicion3
                            2 | 3 | Row Total |
## test_one_hot$V2 | 1 |
 _____|
                         63 | 8 |
       a_helix |
                 769 |
                        0.075 |
                                             0.252 l
##
             0.915 |
                                   0.010
             0.942 l
                          0.105 l
                                   0.004 l
##
                  0.231 |
                           0.019 |
                                   0.002 |
                   45 l
                                    166 |
                            442 |
##
       b_sheet |
                                             653 |
                0.069 |
                                             0.196 |
##
        1
                        0.677 | 0.254 |
                  0.055 |
                          0.734 |
##
                                   0.087
                  0.014 |
                          0.133 |
                                    0.050 |
##
                  -----|----|-
##
          coil |
                     2 |
                            97 I
                                    1741 |
                                             1840 l
            - 1
                  0.001 |
                          0.053 |
                                   0.946 |
                                             0.552 |
                  0.002 |
                          0.161 |
##
                                   0.909 |
                  0.001
                           0.029 |
                                    0.522 |
##
                          602 |
##
    Column Total |
                  816 |
                                   1915 |
##
                  0.245 |
                           0.181 |
                                    0.575 |
         - 1
       -----|----|-----|
##
##
```

```
predicion3 <- factor(predicion3, levels=c(1,2,3),
labels=c("a_helix","b_sheet","coil"))
table(predicion3)</pre>
```

```
## predicion3
## a_helix b_sheet
                      coil
      816
               602
                      1915
confusionMatrix(predicion3,test_one_hot$V2, positive="non_coil")
## Confusion Matrix and Statistics
##
##
             Reference
## Prediction a_helix b_sheet coil
##
      a_helix
                  769
                           45
##
      b sheet
                   63
                           442
                                 97
      coil
                    8
                           166 1741
##
##
## Overall Statistics
##
##
                  Accuracy: 0.8857
##
                     95% CI: (0.8744, 0.8963)
       No Information Rate: 0.5521
##
##
       P-Value [Acc > NIR] : < 2.2e-16
##
##
                      Kappa: 0.8048
##
  Mcnemar's Test P-Value: 1.782e-05
##
##
## Statistics by Class:
##
##
                         Class: a_helix Class: b_sheet Class: coil
## Sensitivity
                                 0.9155
                                                 0.6769
                                                             0.9462
## Specificity
                                 0.9811
                                                 0.9403
                                                             0.8835
## Pos Pred Value
                                 0.9424
                                                 0.7342
                                                             0.9091
## Neg Pred Value
                                 0.9718
                                                 0.9227
                                                             0.9302
## Prevalence
                                 0.2520
                                                 0.1959
                                                             0.5521
## Detection Rate
                                0.2307
                                                 0.1326
                                                             0.5224
## Detection Prevalence
                                0.2448
                                                 0.1806
                                                              0.5746
## Balanced Accuracy
                                                 0.8086
                                                             0.9148
                                 0.9483
Calculamos el error
print(error_3 <- 1-0.8048)</pre>
## [1] 0.1952
Sigo con el \boldsymbol{k5}
library(caret)
Matriz_5<-CrossTable(x=test_one_hot$V2, y=predicion5,</pre>
prop.chisq = FALSE)
```

## ##

```
Cell Contents
## |-----|
## |
         N / Row Total |
N / Col Total |
## |
        N / Table Total |
## |-----|
##
##
## Total Observations in Table: 3333
##
        | predicion5
##
## test_one_hot$V2 | 1 |
                             2 | 3 | Row Total |
                -----|----|
                758 | 76 | 6 | 840 |
##
       a_helix |
                  0.902 | 0.090 | 0.007 |
##
         1
                 0.940 |
                          0.136 |
##
                                   0.003 |
##
                 0.227 |
                          0.023 |
                                  0.002 |
             47 | 391 | 215 |
0.072 | 0.599 | 0.329 |
0.058 | 0.701 | 0.109 |
0.014 | 0.117 | 0.065 |
##
      b_sheet |
                                              653 |
        ##
              coil |
                  1 |
                           91 |
                                     1748 |
          0.001 | 0.049 | 0.001 | 0.163 |
                                  0.950 |
0.888 |
##
                                              0.552 |
             0.000
                          0.027 | 0.524 |
                          558 |
    Column Total | 806 |
                                    1969 | 3333 |
##
                  0.242 | 0.167 |
      1
                                     0.591 |
    -----|----|-----|
##
##
predicion5 <- factor(predicion5, levels=c(1,2,3),</pre>
labels=c("a_helix","b_sheet","coil"))
table(predicion5)
## predicion5
## a_helix b_sheet coil
## 806 558 1969
confusionMatrix(predicion5,test_one_hot$V2, positive="non_coil")
## Confusion Matrix and Statistics
##
##
         Reference
## Prediction a_helix b_sheet coil
  a_helix 758 47 1
##
            76
##
    b_sheet
                  391 91
             6 215 1748
##
    coil
```

```
##
## Overall Statistics
##
##
                Accuracy : 0.8692
##
                  95% CI: (0.8573, 0.8805)
##
      No Information Rate: 0.5521
##
      P-Value [Acc > NIR] : < 2.2e-16
##
##
                   Kappa: 0.7745
##
##
   Mcnemar's Test P-Value: 4.254e-13
##
## Statistics by Class:
##
##
                      Class: a_helix Class: b_sheet Class: coil
## Sensitivity
                            0.9024
                                    0.5988 0.9500
                           0.9807
                                        0.9377
                                                    0.8520
## Specificity
## Pos Pred Value
                           0.9404
                                        0.7007
                                                    0.8878
## Neg Pred Value
                           0.9676
                                         0.9056
                                                    0.9326
                           0.2520
## Prevalence
                                         0.1959
                                                    0.5521
## Detection Rate
                           0.2274
                                         0.1173
                                                   0.5245
0.1674
                                                    0.5908
                                                 0.9010
                                    0.7682
Hago el error para k5
print(error_5 <- 1-0.7745)</pre>
## [1] 0.2255
Este valor es peor
library(caret)
Matriz_7<-CrossTable(x=test_one_hot$V2, y=predicion7,</pre>
prop.chisq = FALSE)
##
##
##
     Cell Contents
## |-----|
           N / Row Total |
N / Col Total |
## |
## |
          N / Table Total |
##
## Total Observations in Table: 3333
##
##
##
                 | predicion7
                                    2 | 3 | Row Total |
## test_one_hot$V2 |
```

```
90 l
                                                    5 I
##
          a_helix |
                         745 |
                                                              840 I
                        0.887 |
                                    0.107 |
                                                             0.252 I
##
                                                0.006 |
##
                        0.936 |
                                    0.174 |
                                                0.002 |
##
                        0.224 |
                                    0.027 |
                                                 0.002 |
##
                            50 |
                                     348 |
                                                  255 |
                                                               653 I
          b_sheet |
                        0.077 |
                                                0.391 |
                                                            0.196 |
##
                                   0.533 |
                                   0.672 |
##
                   Ι
                        0.063 |
                                               0.126 |
##
                        0.015 |
                                    0.104 |
                                                 0.077 |
##
             coil |
                           1 |
                                      80 l
                                                 1759 |
                                                             1840 |
                                 0.043 |
                        0.001 |
                                                0.956 |
                                                            0.552 l
##
##
                        0.001 |
                                   0.154 |
                                                0.871 |
##
                        0.000 |
                                    0.024 |
                                                0.528 |
##
##
      Column Total |
                         796 l
                                      518 |
                                                  2019 |
                                                              3333 |
                        0.239 |
                                                0.606 |
                                    0.155 |
##
##
##
predicion7 <- factor(predicion7, levels=c(1,2,3),</pre>
labels=c("a_helix","b_sheet","coil"))
table(predicion7)
## predicion7
## a_helix b_sheet
                     coil
##
     796 518
                     2019
```

confusionMatrix(predicion7,test\_one\_hot\$V2, positive="non\_coil")

```
## Confusion Matrix and Statistics
##
##
            Reference
## Prediction a_helix b_sheet coil
      a helix 745 50 1
##
##
      b_sheet
                 90
                         348
                               80
      coil
                   5
                         255 1759
##
##
## Overall Statistics
##
##
                 Accuracy : 0.8557
##
                   95% CI: (0.8433, 0.8674)
##
      No Information Rate : 0.5521
##
      P-Value [Acc > NIR] : < 2.2e-16
##
##
                    Kappa: 0.749
##
##
   Mcnemar's Test P-Value : < 2.2e-16
##
## Statistics by Class:
##
```

```
##
                      Class: a_helix Class: b_sheet Class: coil
## Sensitivity
                              0.8869
                                            0.5329 0.9560
## Specificity
                              0.9795
                                            0.9366
                                                       0.8259
## Pos Pred Value
                              0.9359
                                            0.6718
                                                       0.8712
## Neg Pred Value
                              0.9626
                                            0.8917
                                                       0.9384
## Prevalence
                             0.2520
                                            0.1959
                                                       0.5521
## Detection Rate
                              0.2235
                                            0.1044
                                                       0.5278
## Detection Prevalence
                                            0.1554
                            0.2388
                                                       0.6058
## Balanced Accuracy
                              0.9332
                                            0.7347
                                                       0.8909
```

Hago el error a partir del valor de kappa

```
print(error_7 <- 1-0.749)</pre>
```

```
## [1] 0.251
```

Hago el ultimo el valor de k11

```
library(caret)
Matriz_11<-CrossTable(x=test_one_hot$V2, y=predicion11,
prop.chisq = FALSE)</pre>
```

## ## ## ## ## ## ## ##	## ## Cell Contents ##    ##   N   ##   N / Row Total   ##   N / Col Total   ##   N / Table Total   ##    ## ## ## ## Total Observations in Table: 3333									
##		l								
## ##	test_one_hot\$V2	predicion11	L L 2	J 3	Row Total					
##		 								
##	a_helix	768	71	1	840					
##		0.914	0.085	0.001	0.252					
##		0.941	0.171	0.000						
##		0.230	0.021	0.000						
## ##	h -h - +		300							
##	b_sheet	48     0.074	300 0.459	305   0.467	653     0.196					
##		0.059	0.721	0.145	l 0.130					
##		0.014	0.090	0.092						
##										
##	coil	0	45	1795	1840					
##		0.000	0.024	0.976	0.552					
##		0.000	0.108	0.854						

```
0.000 | 0.014 | 0.539 |
## -----|----|-----|
    Column Total | 816 |
                                       2101 |
                              416 |
                                       0.630 |
##
       |
                   0.245 |
                            0.125 |
##
     -----|-----|-----|
##
##
predicion11 <- factor(predicion11, levels=c(1,2,3),</pre>
labels=c("a_helix","b_sheet","coil"))
table(predicion11)
## predicion11
## a_helix b_sheet
                 coil
     816
                 2101
##
            416
hago la ultima matriz de confusion con el valor de k11
confusionMatrix(predicion11,test_one_hot$V2, positive="non_coil")
```

```
## Confusion Matrix and Statistics
##
##
            Reference
## Prediction a_helix b_sheet coil
     a_helix 768 48
##
##
     b_sheet
                  71
                         300 45
                         305 1795
##
     coil
##
## Overall Statistics
##
##
                 Accuracy: 0.859
##
                   95% CI : (0.8467, 0.8706)
##
      No Information Rate: 0.5521
##
      P-Value [Acc > NIR] : < 2.2e-16
##
##
                    Kappa: 0.7508
##
   Mcnemar's Test P-Value : < 2.2e-16
##
##
## Statistics by Class:
##
##
                       Class: a_helix Class: b_sheet Class: coil
## Sensitivity
                               0.9143
                                             0.45942
                                                         0.9755
## Specificity
                               0.9807
                                             0.95672
                                                         0.7950
## Pos Pred Value
                               0.9412
                                             0.72115
                                                         0.8544
## Neg Pred Value
                               0.9714
                                             0.87899
                                                          0.9635
## Prevalence
                               0.2520
                                             0.19592
                                                          0.5521
## Detection Rate
                              0.2304
                                             0.09001
                                                          0.5386
## Detection Prevalence
                             0.2448
                                             0.12481
                                                          0.6304
## Balanced Accuracy
                             0.9475
                                             0.70807
                                                          0.8853
```

Hago el ultimo error a partir del valor kappa

print(error\_11 <- 1-0.7508)</pre>

## [1] 0.2492

Como podemos observar el mejor ha sido el k1 con un valor kappa = 0.8392, y un error = 0.0954, los modelos van empeorando entre ellos el k3 y k11, pero los peores son el k5 y k7, Podemos ver que los datos sacados en las curvas ROC son buenos estan muy proximos a 1, el mejor AUC en las curvas ROOC es el k11 con un valor de AUC = 0.9997547.